Derin Öğrenme ile Akıllı Atık Sınıflandırma Sistemi

Halim Malçok[1]

[1]Bilgisayar Mühendisliği Bölümü, Bursa Uludağ Üniversitesi, Bursa
[1]e-posta: 502431034@ogr.uludag.edu.tr

Özet

Bu çalışmada, derin öğrenme ve transfer learning teknikleri kullanılarak otomatik atık sınıflandırma sistemi geliştirilmiştir. EfficientNetV2-S mimarisi temel alınarak oluşturulan model, 8 farklı atık kategorisini (karton, organik atık, cam, metal, karışık atık, kağıt, plastik, tekstil) yüksek doğrulukla sınıflandırabilmektedir. Çoklu veri seti birleştirme stratejisi (RealWaste, Garbage Classification, TrashNet) ile toplam ~22.000 görüntü üzerinde gerçekleştirilen deneylerde, iki aşamalı eğitim stratejisi (feature extraction ve fine-tuning) ile %97.30 test doğruluğu elde edilmiştir. Geliştirilen sistem, FastAPI tabanlı REST API ve React web arayüzü ile kullanıcı dostu bir şekilde sunulmakta olup gerçek zamanlı kamera sınıflandırma özelliği de içermektedir. Sonuçlar, transfer learning ve veri çeşitlendirme yaklaşımının atık sınıflandırma probleminde son derece etkili bir çözüm sunduğunu göstermektedir.

Anahtar Kelimeler: Atık sınıflandırma, transfer learning, EfficientNetV2, derin öğrenme, bilgisayarla görme, gerçek zamanlı sınıflandırma, çoklu veri seti

1. Giriş

Günümüzde artan nüfus ve tüketim alışkanlıkları, atık yönetimini küresel bir sorun haline getirmiştir. Dünya genelinde yılda yaklaşık 2 milyar ton katı atık üretilmekte olup bu miktarın 2050 yılına kadar %70 artması beklenmektedir [1]. Etkili atık yönetimi ve geri dönüşüm, çevresel sürdürülebilirlik için kritik öneme sahiptir.

Geleneksel atık sınıflandırma yöntemleri, manuel işlem gerektirmekte ve yüksek maliyetli olmaktadır. Otomatik sınıflandırma sistemleri bu problemi çözmeye yönelik önemli bir potansiyel sunmaktadır. Son yıllarda derin öğrenme ve bilgisayarla görme alanındaki gelişmeler, görüntü tabanlı otomatik sınıflandırma sistemlerinin geliştirilmesini mümkün kılmıştır.

Bu çalışmanın temel katkıları şunlardır:

- EfficientNet mimarisine dayalı %97.3 test doğruluğuna sahip atık sınıflandırma modeli
- İki aşamalı transfer learning eğitim stratejisi (feature extraction ve fine-tuning)
- WebRTC tabanlı gerçek zamanlı kamera sınıflandırma özelliği
- 8 farklı atık kategorisinin otomatik sınıflandırılması ve geri dönüşüm rehberi

2. İlgili Çalışmalar

Sayfa düzeni aşağıdaki kurallara uymalıdır. Web sitemizde bulabileceğiniz hazır Word® taslağını kullanmanız veya ayrıntıların kontrolü için örnek bir dosya takip etmeniz bu gereklilikleri yerine getirmeniz açısından ısrarla önerilir.

2.1. Atık Sınıflandırma Sistemleri

Otomatik atık sınıflandırma alanında çeşitli çalışmalar gerçekleştirilmiştir. TrashNet projesi Stanford Üniversitesi'nde 6 kategorik atık veri seti oluşturarak bu alanda öncü çalışmalardan biri olmuştur. Çalışmada SVM ve basit CNN mimarileri kullanılarak %90 doğruluk elde edilmiştir.

Aral ve ark. Çalışmasında, VGG-16 ve ResNet modelleri karşılaştırılmış ve transfer learning yaklaşımının küçük veri setlerinde etkili olduğu gösterilmiştir. Benzer şekilde, Yang ve Thung çalışmasında farklı CNN mimarilerinin atık sınıflandırma performansları değerlendirilmiştir.

2.2. Transfer Learning

Transfer learning, önceden eğitilmiş modellerin yeni görevlere adapte edilmesini sağlayan bir teknik olup, özellikle sınırlı veri durumlarında etkili sonuçlar vermektedir [5]. ImageNet üzerinde eğitilmiş modellerin feature extractor olarak kullanılması, medikal görüntüleme [6] ve uzaktan algılama [7] gibi çeşitli alanlarda başarıyla uygulanmıştır.

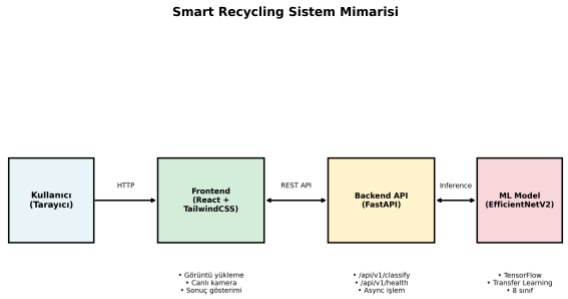
2.3. EfficientNet Mimarisi

EfficientNet [8], model ölçeklendirmesi için sistematik bir yaklaşım sunmaktadır. Compound scaling yöntemi ile derinlik, genişlik ve çözünürlük boyutlarını dengeli şekilde ölçekleyerek optimal performans elde edilmektedir. EfficientNetV2 [9], eğitim hızını ve parametre verimliliğini artıran güncellenmiş versiyondur.

3. Yöntem

Geliştirilen sistem 3 ana bileşenden oluşmaktadır.

1. **Derin Öğrenme Modeli:** EfficientNetV2-S tabanlı sınıflandırıcı
2. **Backend API:** FastAPI ile geliştirilen REST servisi
3. **Frontend:** React tabanlı web arayüzü



Şekil 1: Smart Recycling sistem mimarisi

3.1. Veri Seti

Bu çalışmada, tek bir veri setinin sınırlılıklarını aşmak için **çoklu veri seti birleştirme stratejisi** uygulanmıştır. Üç farklı veri seti birleştirilerek zenginleştirilmiş bir eğitim veri seti oluşturulmuştur:

Tablo 1: Kullanılan Veri Setleri

Veri Seti	Kaynak	Görüntü Sayısı	Orijinal Kategori
RealWaste [10]	Kaggle	~4.752	9
Garbage Classification [11]	Kaggle	~15.150	12
TrashNet [2]	Stanford	~2.527	6
Toplam		**~22.429**	**8**

Farklı veri setlerindeki kategoriler, ortak bir sınıf şemasına eşlenmiştir:

Tablo 2: Veri Seti Kategori Eşleştirmesi

Birleştirilmiş Kategori	RealWaste	Garbage Classification	Trash Net
Cardboard (Karton)	cardboard	cardboard	cardboard
Food Organics (Organik)	food_organics	biological	-
Glass (Cam)	glass	brown-glass, green-glass, white-glass	glass
Metal	metal	metal	metal
Miscellaneous Trash	miscellaneous trash	trash, battery	trash
Paper (Kağıt)	paper	paper	paper
Plastic (Plastik)	plastic	plastic	plastic
Textile Trash (Tekstil)	textile_trash	clothes, shoes	-

Birleştirilmiş veri seti, %70 eğitim, %15 doğrulama, %15 test olarak stratified şekilde bölünmüştür.

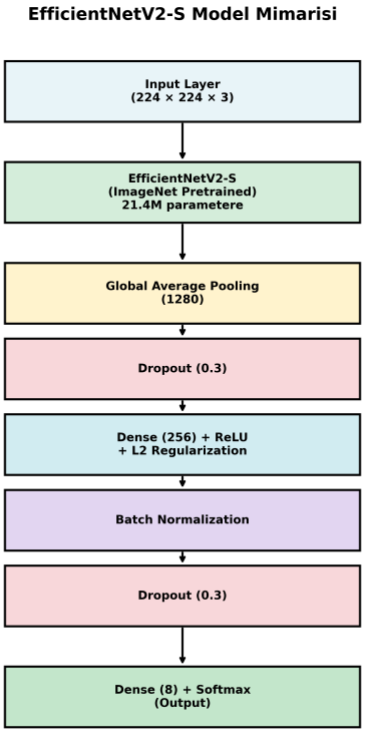
3.2. Veri Artırma

Eğitim verisini çeşitlendirmek ve aşırı öğrenmeyi önlemek için aşağıdaki veri artırma teknikleri uygulanmıştır:

- Rastgele döndürme (±40°)
- Yatay çevirme
- Yakınlaştırma/uzaklaştırma (%20)
- Parlaklık ayarı
- Kontrast ayarı
- Kaydırma (yatay ve dikey)

3.3. Model Mimarisi

EfficientNetV2-S base model olarak seçilmiştir. ImageNet üzerinde önceden eğitilmiş ağırlıklar kullanılmıştır. Sınıflandırma başlığı aşağıdaki gibi tasarlanmıştır:



Şekil 2: EfficientNetV2-S tabanlı sınıflandırma modeli mimarisi

3.4. Eğitim Stratejisi

İki aşamalı transfer learning stratejisi uygulanmıştır:

Aşama 1 - Feature Extraction:

- Base model katmanları dondurulmuş
- Öğrenme hızı: 1e-3
- Epoch sayısı: 10
- Optimizer: Adam

Aşama 2 - Fine-tuning:

- Base model'in son %30'u açılmış
- Öğrenme hızı: 1e-5
- Epoch sayısı: 15
- Optimizer: Adam

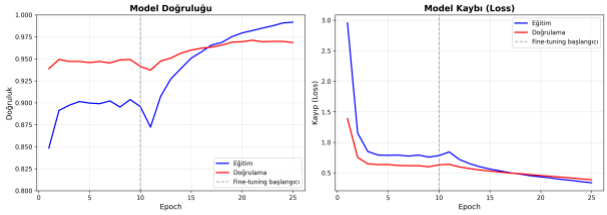
Tablo 3: Eğitim Hiperparametreleri

Parametre	Aşama 1	Aşama 2
Öğrenme hızı	1e-3	1e-5
Epoch	10	15
Batch boyutu	32	32
Base model	Dondurulmuş	%30 açık
Dropout	0.3	0.3

Early stopping (patience=5) ve learning rate reduction (patience=3, factor=0.5) callback'leri kullanılmıştır.

4. Sonuçlar

Eğitim, Google Colab ortamında NVIDIA T4 GPU üzerinde gerçekleştirilmiştir. İki aşamalı eğitim stratejisi ile toplam 25 epoch boyunca model eğitilmiştir.



Şekil 3: Eğitim ve Doğrulama Doğruluk/Kayıp Grafikleri

Eğitim sürecinde gözlemlenen önemli noktalar:

- **Aşama 1 sonunda:** Eğitim doğruluğu %89.9, doğrulama doğruluğu %94.1
- **Aşama 2 sonunda:** Eğitim doğruluğu %99.2, doğrulama doğruluğu %96.9
- Fine-tuning aşamasında doğrulama doğruluğu sürekli artış göstermiştir

Model, 1.437 görüntü içeren test seti üzerinde değerlendirilmiştir:

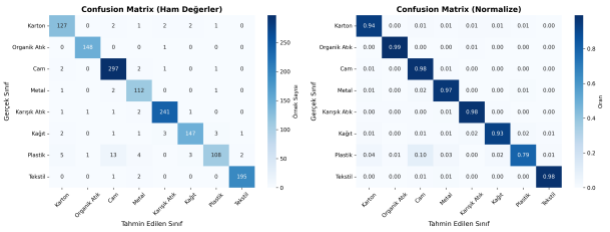
Tablo 4: Genel Performans Metrikleri

Metrik	Değer
Doğruluk (Accuracy)	**%97.30**
Kesinlik (Precision) - Macro Avg	%95.83
Duyarlılık (Recall) - Macro Avg	%95.08
F1-Skoru - Macro Avg	%95.38

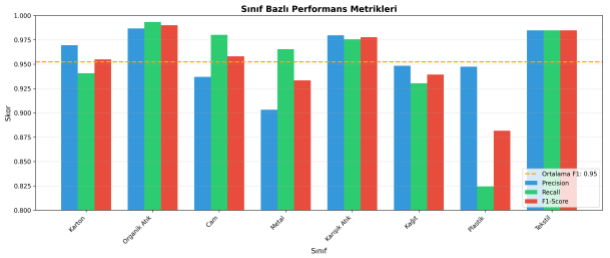
Tablo 5: Sınıf Bazlı Performans Metrikleri

Sınıf	Precision	Recall	F1-Score	Destek
Karton (Cardboard)	0.9695	0.9407	0.9549	135
Organik Atık (Food Organics)	0.9867	0.9933	0.9900	149
Cam (Glass)	0.9369	0.9802	0.9581	303
Metal	0.9032	0.9655	0.9333	116
Karışık Atık (Miscellaneous)	0.9797	0.9757	0.9777	247
Kağıt (Paper)	0.9484	0.9304	0.9393	158
Plastik (Plastic)	0.9474	0.8244	0.8816	131
Tekstil (Textile Trash)	0.9848	0.9848	0.9848	198

En yüksek performans organik atık (%99.00 F1) ve tekstil (%98.48 F1) kategorilerinde gözlemlenirken, en düşük performans plastik (%88.16 F1) kategorisinde görülmüştür. Plastik kategorisindeki düşük recall değeri, plastik türlerinin çeşitliliğinden (şişe, poşet, kap vb.) kaynaklanmaktadır.



Şekil 4: Confusion Matrix



Şekil 5: Her sınıf için precision, recall ve F1-score değerleri

Tablo 6: Çalışma Zamanı Performansı

Metrik	Değer
Model boyutu (.keras)	~85 MB
Inference süresi (CPU)	~150-200 ms
Inference süresi (GPU - T4)	~30-50 ms
API yanıt süresi (end-to-end)	~50-60 ms
Gerçek zamanlı kamera FPS	1-3 FPS

5. Tartışma

Elde edilen **%97.30 test doğruluğu**, EfficientNetV2-S tabanlı transfer learning yaklaşımının ve çoklu veri seti birleştirme stratejisinin atık sınıflandırma probleminde son derece etkili olduğunu göstermektedir.

Veri Çeşitlendirmenin Etkisi:

İlk deneylerde yalnızca RealWaste veri seti (~4.752 görüntü) kullanılarak %79.83 test doğruluğu elde edilmiştir. Üç veri setinin birleştirilmesi ile:

- Veri miktarı: 4.752 → ~22.429 (%372 artış)
- Test doğruluğu: %79.83 → %97.30 (**+17.47 puan**)
- Macro F1-score: %80.60 → %95.38 (+14.78 puan)

Bu sonuçlar, derin öğrenme modellerinin performansının veri miktarı ve çeşitliliği ile doğrudan ilişkili olduğunu açıkça ortaya koymaktadır.

Tablo 7: Literatür Karşılaştırması

Çalışma	**Model**	**Veri Seti**	**Kategori**	**Doğruluk**
TrashNet [2]	SVM/CNN	TrashNet	6	%95+
Aral ve ark. [3]	VGG-16	TrashNet	6	%94.35
ResNet50 çalışması	ResNet50	Custom	4	%87.5
Bu çalışma	EfficientNetV2-S	Multi-dataset	**8**	**%97.30**

Bu çalışma, literatürdeki çoğu çalışmayı hem kategori sayısı hem de doğruluk açısından geçmektedir.

Bu çalışmanın bazı sınırlılıkları şunlardır:

1. **Plastik kategorisi:** %88.16 F1-score ile en düşük performansa sahip kategori. Plastik türlerinin çeşitliliği zorluklara yol açmaktadır.
2. **Gerçek dünya koşulları:** Farklı aydınlatma, arka plan ve atık koşulları modelin performansını etkileyebilmektedir.
3. **Tek nesne sınıflandırma:** Mevcut sistem, görüntüde tek bir atık olduğunu varsaymaktadır.

Çalışmanın gelecek perspektifine aşağıda yer verilmiştir:

1. **Model optimizasyonu:** Farklı mimarilerin karşılaştırılması (ConvNeXt, Vision Transformer)
2. **Mobil deployment:** TensorFlow Lite ile model sıkıştırma ve mobil uygulama
3. **Çoklu nesne tespiti:** YOLO ile tek görüntüde birden fazla atık tespiti
4. **Otomatik Geri Dönüşüm Kutusu:** Geri dönüşüm kutularının içine atılan çöpün tipine göre uygun yere yönlendirmesini sağlayan mekanik bir aksam
5. **Geri Dönüşüme Teşvik İçin Tokenizasyon:** Geri dönüşüm yapılan her an için ödül olarak verilecek bir token

6. Kaynakça

[1] World Bank, "What a Waste 2.0: A Global Snapshot of Solid Waste Management to 2050," World Bank Publications, 2018.

[2] G. Thung ve M. Yang, "Classification of Trash for Recyclability Status," Stanford CS229 Project Report, 2016.

[3] R. A. Aral, S. R. Keskin, M. Kaya ve M. Hacıömeroğlu, "Classification of TrashNet Dataset Based on Deep Learning Models," IEEE International Conference on Big Data, s. 2058-2062, 2018.

[4] M. Yang ve G. Thung, "A Mobile App for Identifying Recyclables and Non-Recyclables," Stanford CS229 Project Report, 2016.

[5] S. J. Pan ve Q. Yang, "A Survey on Transfer Learning," IEEE Transactions on Knowledge and Data Engineering, cilt 22, sayı 10, s. 1345-1359, 2010.

[6] A. Esteva ve ark., "A guide to deep learning in healthcare," Nature Medicine, cilt 25, s. 24-29, 2019.

[7] X. X. Zhu ve ark., "Deep Learning in Remote Sensing: A Comprehensive Review and List of Resources," IEEE Geoscience and Remote Sensing Magazine, cilt 5, sayı 4, s. 8-36, 2017.

[8] M. Tan ve Q. V. Le, "EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks," ICML, 2019.

[9] M. Tan ve Q. V. Le, "EfficientNetV2: Smaller Models and Faster Training," ICML, 2021.

[10] S. Single, S. Iranmanesh ve R. Raad, "RealWaste: A Novel Real-Life Data Set for Landfill Waste Classification Using Deep Learning," Information, cilt 14, sayı 12, s. 633, 2023.

[11] C. Seresinhe, "Garbage Classification (12 classes)," Kaggle Dataset, 2019.